

Universidade Federal de Sergipe

Departamento de Computação

Qualidade de Software



ATIVIDADE AVALIATIVA 3

Métricas Automáticas versus Avaliação Humana (GQM)

Projeto Analisado – AnythingLLM

Repositório do Projeto – Clique Aqui

Repositório da Avaliação – Clique Aqui

Vídeo da Análise – Clique Aqui

ARIEL SANTOS SOUZA - 202400050731

EMANUEL CHAGAS MELO RIBEIRO - 202400050820

FERNANDA SILVA FARIAS - 202400101527

JOÃO LUCAS MACHADO DA SILVA - 202400051130

KAROL STHEFANNY DA CRUZ MENEZES - 202400050947

MARIANE MARTINS SANTOS - 202400072336

NYCOLLY SOUZA SENA - 202400051004

GLAUCO DE FIGUEIREDO CARNEIRO - Orientador

São Cristóvão – SE

Outubro de 2026

SUMÁRIO

SUMÁRIO **1**
TABELA DE CONTRIBUIÇÃO INDIVIDUAL **3**
DECLARAÇÃO DE USO DE IA GENERATIVA **3**
GQM **5**
Objetivo 5
Escopo do experimento 5
Medidas 5
Limiar do Sinal Automático (τ) 6
Normalização e Referência Vazia 6
Critério de Avanço e Bloqueio 7
CASOS **8**
Introdução 8
Casos de Teste 8
Documentos Utilizados no Workspace 9
VERSÕES **11**
Introdução 11
Versão A — Baseline 11
Versão B — Prompt Estruturado 12
Fator de Mudança e Justificativa 13
Condições de Comparabilidade 13
SAÍDAS **14**
Introdução 14
Resultados das Execuções 14
Conclusão das Saídas 16
AVALIAÇÕES **17**
Introdução 17
Avaliação R1 17
Avaliação R2 18
Resultado da Concordância 18
Consenso entre os Avaliadores 18
ANÁLISE E DECISÃO **20**
Introdução 20
Tabela Consolidada 20
Concordância e Métricas por Versão 21
Gráfico 21
Análise de Divergências e Casos-Limite 22
Decisão 22
Respostas às Questões de Análise 23
Q1. A versão B atende melhor à tarefa do que a versão A? 23
Q2. O sinal automático representa a adequação das respostas? 24
Limitações 24
REFERÊNCIAS **25**

TABELA DE CONTRIBUIÇÃO INDIVIDUAL

Nome	**Contribuição**
ARIEL SANTOS SOUZA	Saídas
EMANUEL CHAGAS MELO RIBEIRO	Avaliação
FERNANDA SILVA FARIAS	Casos
JOÃO LUCAS MACHADO DA SILVA	Avaliação
KAROL STHEFANNY DA CRUZ MENEZES	Análise Observação: A discente participou de todas as etapas de desenvolvimento e análise do relatório, ausentando-se apenas da apresentação devido a compromisso acadêmico prévio de ministração de oficina no mesmo horário. Justificado via e-mail.
MARIANE MARTINS SANTOS	GQM
NYCOLLY SOUZA SENA	Decisão

DECLARAÇÃO DE USO DE IA GENERATIVA

Declaramos que, durante a elaboração deste projeto e de sua respectiva documentação, foram utilizadas as ferramentas de Inteligência Artificial (IA) generativa Google Gemini e Claude.

O uso dessas tecnologias teve como objetivo otimizar o processo de desenvolvimento e documentação, sendo aplicadas especificamente nas seguintes atividades:

- **Estruturação**: Auxílio na definição da estrutura lógica, tópicos e formatação dos documentos gerados.
- **Redação e Revisão**: Apoio na geração inicial de ideias, bem como na correção gramatical, ortográfica e refinamento da clareza e coesão dos textos.
- **Arquivos de Apoio**: Auxílio na criação, organização e formatação de scripts, tabelas e demais arquivos de apoio inerentes ao desenvolvimento do projeto.

Ressaltamos que todo o conteúdo gerado, sugerido ou corrigido pelas referidas ferramentas de IA foi rigorosamente lido, revisado, validado e adaptado pelos autores deste trabalho, que assumem total responsabilidade pela precisão, qualidade e veracidade do conteúdo final apresentado.

GQM

Objetivo

Analisar as respostas do fluxo de perguntas e respostas com fontes (RAG) do AnythingLLM, nas versões A (prompt direto, baseline) e B (prompt estruturado, única mudança principal), com o propósito de avaliar se a mudança melhora a qualidade das respostas e se uma métrica automática simples representa essa qualidade, do ponto de vista da equipe de Qualidade de Software.

Pergunta	Medida
Q1. A versão B atende melhor à tarefa do que a versão A?	M2 — Taxa de aprovação humana
Q2. O sinal automático representa a adequação das respostas?	M1 — F1 lexical e M3 — Concordância auto–humano

Escopo do experimento

Item	Definição
Fluxo	Usuário → prompt → recuperação de contexto (busca vetorial nos documentos do workspace) → modelo → resposta + fontes
Versão A	Prompt direto: apenas a pergunta
Versão B	Prompt estruturado: objetivo, contexto, restrições (responder só com base no documento, não inventar valores, declarar quando não houver evidência) e formato. O mesmo molde é aplicado aos seis casos.
Fatores mantidos fixos	Gemini 2.5 Flash, workspace, documentos indexados, configuração padrão do workspace e sessão limpa a cada execução
Casos	CT01–CT04: perguntas funcionais com resposta presente nos documentos; CT05: pergunta sem evidência nos documentos (resposta esperada: declarar o limite); CT06: paráfrase ou erro de digitação de CT01
Execuções	6 casos × 2 versões = 12 saídas, uma execução por caso/versão

Medidas

	M1 — F1 lexical	M2 — Taxa de aprovação humana	M3 — Concordância auto–humano
Unidade	Adimensional, 0 a 1, por saída (agregado por versão: média e mediana)	Proporção (n/6) ou %, por versão	Proporção (n/12)
Fórmula	`P = comuns / tokens_resposta`; `R = comuns / tokens_referência`; `F1 = 2·P·R / (P+R)`; `F1 = 0` se não houver sobreposição ou a resposta for vazia	`aprovadas_humano / 6`, calculada para A e para B. Aprovada = Correção 2, Relevância 2, Suporte 2 **e** falha crítica = 0	`decisões iguais / 12` (6 casos × 2 versões), comparando a decisão automática com a decisão humana final
Denominador	1 por saída; 6 saídas por versão	6 por versão	12
Limitação	Mede só sobreposição de palavras, não significado. Respostas do RAG tendem a ser longas e a citar fontes, o que reduz a precisão lexical mesmo quando corretas. A versão B, por ser mais estruturada, pode alterar o F1 só pelo formato. Paráfrase correta pode ter F1 baixo, e trocar "R$ 55 milhões" por "R$ 45 milhões" mantém muitas palavras, mas muda o fato. Em CT05 (abstenção), a redação varia e o F1 tende a ser instável.	Apenas 6 casos por versão: cada caso vale ~16,7 p.p., então diferenças são grosseiras e sem poder estatístico. CT06 é variação de CT01 (não é observação independente). Em 8 das 12 saídas a decisão vem de um único avaliador (R1). O cegamento pode ser parcial, pois o formato da resposta de B tende a revelar a versão.	Depende diretamente do valor de τ. Não corrige concordância ao acaso (sem kappa). Com poucos casos, uma única divergência altera muito o valor. As duas decisões são binárias e perdem a nuance das notas 0/1/2.

Decisão humana final (usada em M2 e M3): em CT01 e CT05, o consenso justificado de R1 e R2 quando houver divergência (R1 e R2 originais são preservados) nas
demais saídas, a nota de R1.

Falha crítica (0/1), regra prévia: Vale 1 se a saída: (a) afirma como certo um valor ou fato contrário à fonte; (b) inventa dado, ou atribui a resposta a documento/fonte inexistente ou sem relação com o tema; ou (c) em CT05, responde com conteúdo fabricado em vez de declarar que não há informação nos documentos. Saída vazia ou com falha de execução **não** é falha crítica por si só, mas é registrada e reprovada (Relevância 0). Os documentos do workspace são sintéticos e sem dados pessoais.

Limiar do Sinal Automático (τ)

- **Regra:** o sinal automático **aprova** a saída se F1 ≥ τ; caso contrário, **reprova**.
- **Valor: τ = 0,5**.
- **Justificativa:** valor didático aceito pela atividade. Como as referências são curtas e revisadas por pessoa, exigir F1 ≥ 0,5 significa que ao menos cerca de metade dos tokens da resposta e da referência coincidem, nível intermediário que evita aprovar sobreposição acidental sem exigir cópia literal. Não há conjunto de calibração novo; τ foi fixado antes da bateria e não será alterado após ver os resultados. Eventuais ajustes seriam apenas discutidos como análise posterior, sem substituir o resultado oficial.

Normalização e Referência Vazia

Normalização e tokenização:

1. Normalização Unicode NFC.
2. casefold sem remover acentos.
3. Tokens de palavras (sequências alfanuméricas; pontuação descartada; números são tokens, e "R$ 55" gera os tokens r e 55).
4. Sem stemming, sem remoção de stopwords.
5. Tokens em comum = interseção de multiconjuntos (cada token conta no máximo o número de vezes que aparece nos dois textos).
6. O F1 é calculado sobre o texto da resposta exibido no chat; a lista de fontes e as indicações visuais da interface ficam de fora.

Casos especiais:

- Resposta vazia ou sem sobreposição: F1 = 0 e sinal automático reprova.
- Referência sem tokens após normalização: o caso é corrigido antes da bateria (a referência é revisada por pessoa). Se ocorrer depois, o caso é declarado inválido e registrado, sem inventar score de F1.
- Falha de execução: registrada como saída vazia e tratada pelos critérios acima; nunca descartada.

Critério de Avanço e Bloqueio

A decisão se baseia na avaliação humana. O F1 e a concordância informam a Q2, mas não decidem sobre a versão B.

Decisão	Condição (definida antes do teste)
Levar B à próxima etapa	Aprovação humana de B ≥ aprovação de A + 1/6 (ao menos um caso aprovado a mais) e nenhuma falha crítica em B
Manter A	Aprovação de B ≤ aprovação de A (sem ganho), ou B apresenta falha crítica em caso em que A não falhou
Revisar	Houver ganho de B, mas também falha crítica em B; ou falhas críticas em ambas as versões; ou o F1 de B subir sem melhora na aprovação humana (indício de ganho apenas na métrica)

Condição de bloqueio: qualquer falha crítica em B bloqueia o avanço de B, independentemente de F1 ou taxa de aprovação.

CASOS

Introdução

Esta seção apresenta os seis casos de teste que serão utilizados na avaliação funcional do fluxo de perguntas e respostas com fontes (RAG) do AnythingLLM.
Os testes serão realizados utilizando como contexto os documentos fictícios anexados ao workspace, referentes à Empresa Exemplo S.A. Os documentos contêm informações organizacionais, políticas de benefícios e dados financeiros, permitindo formular perguntas com respostas previamente conhecidas e verificar a capacidade do sistema de recuperar informações relevantes.

Os casos foram definidos para contemplar perguntas funcionais com evidências disponíveis (CT01–CT04), uma pergunta sem evidência suficiente para responder (CT05) e uma variação de pergunta por paráfrase (CT06).
O objetivo desta etapa é estabelecer os prompts e suas respectivas respostas de referência, que serão utilizados posteriormente nas execuções e avaliações das versões A e B do experimento.

Casos de Teste

ID	Tipo	Pergunta (prompt)	Fonte esperada	Resposta esperada
CT01	Funcional — informação direta	Qual é o valor do vale-refeição oferecido pela empresa por dia útil trabalhado?	Política de Benefícios, seção 2 — Vale-refeição, página 1.	R$ 50,00 por dia útil trabalhado.
CT02	Funcional — informação direta	Qual é a missão da Empresa Exemplo S.A.?	Manual Organizacional, seção 2 — Missão, página 1.	Simplificar a gestão de pequenas e médias empresas por meio de soluções digitais acessíveis, seguras e fáceis de usar, contribuindo para o crescimento sustentável dos clientes.

CT03	Funcional — informação numérica	Qual foi a receita líquida da empresa no exercício de 2025?	Relatório Financeiro 2025, seção 2 — Demonstração de resultado 2025, página 1.	R$ 48,6 milhões.
CT04	Funcional — informação direta	Após quanto tempo de contratação os colaboradores passam a ter direito ao plano de saúde?	Política de Benefícios, seção 3 — Plano de saúde, página 1.	Após o período de experiência de 90 dias.
CT05	Sem evidência suficiente — abstenção	Qual foi o valor do bônus anual por desempenho pago aos colaboradores em 2025?	Nenhum dos documentos do workspace apresenta informações sobre bônus anual por desempenho.	O sistema deve declarar explicitamente que não encontrou informações sobre o pagamento ou o valor de bônus anual por desempenho nos documentos disponíveis. Não deve inventar valores, confirmar a existência do benefício ou apresentar informações não sustentadas pelas fontes.
CT06	Variação funcional — paráfrase	Quanto a empresa disponibiliza de auxílio-refeição para cada dia útil trabalhado?	Política de Benefícios, seção 2 — Vale-refeição, página 1. Caso de origem: CT01.	R$ 50,00 por dia útil trabalhado. A pergunta utiliza uma formulação diferente da original, mantendo a intenção de consultar o mesmo benefício e sua quantia.

Documentos Utilizados no Workspace

Os seguintes documentos fictícios serão indexados no workspace e utilizados como base de conhecimento para a execução dos casos de teste.

Documento	**Conteúdo utilizado**
Manual-Organizacional.pdf	Missão, visão, valores e objetivos estratégicos da empresa.

Politica-Beneficios.pdf	Vale-refeição, plano de saúde, home office e demais benefícios oferecidos aos colaboradores.
Relatorio-Financeiro-2025.pdf	Resultados financeiros, indicadores e comparação com as metas do exercício de 2025.

VERSÕES

Introdução

Esta seção apresenta as configurações das duas versões do experimento que serão utilizadas na avaliação do fluxo de perguntas e respostas com fontes (RAG) do AnythingLLM.

A Versão A será utilizada como baseline, empregando um prompt direto, contendo apenas a pergunta do usuário. A Versão B utilizará um prompt estruturado, mantendo todas as demais condições do experimento e alterando exclusivamente a formulação do prompt.

Cada um dos seis casos de teste (CT01–CT06) será executado uma vez em cada versão, totalizando 12 saídas. Todas as respostas, incluindo eventuais falhas de execução ou saídas vazias, serão registradas sem descarte ou substituição.
Configuração das versões

Versão A — Baseline

Item	Configuração
Identificação	Versão A
Tipo	Baseline
Prompt	Prompt direto, contendo apenas a pergunta original do caso de teste, sem instruções adicionais.
Modelo	Gemini 2.5 Flash
Revisão	Não aplicável ao prompt direto.
Parâmetros	Configuração padrão do workspace, sem alterações específicas para os casos.
Fonte/contexto	Documentos fictícios indexados no workspace: Manual Organizacional v1.0, Política de Benefícios v2.0 e Relatório Financeiro 2025. O contexto efetivamente recuperado será registrado em cada execução.
Data	09/11/2026

Prompt utilizado:

```
Textproto
{pergunta do caso de teste}
```

Versão B — Prompt Estruturado

Item	Configuração
Identificação	Versão B
Tipo	Experimental
Prompt	Prompt estruturado, contendo objetivo, contexto, restrições e formato de resposta.
Modelo	Gemini 2.5 Flash
Revisão	Prompt estruturado — versão 1.0.
Parâmetros	Mesma configuração padrão do workspace utilizada na Versão A.
Contexto	Os mesmos documentos fictícios indexados no workspace da Versão A. O contexto efetivamente recuperado será registrado em cada execução.
Data	09/11/2026

Prompt utilizado:

```
Textproto
Objetivo:
Responder à pergunta do usuário utilizando as informações disponíveis nos documentos do workspace.

Contexto:
Considere os documentos recuperados pelo sistema como fonte de informação para elaborar a resposta.

Restrições:
- Responda somente com base nas informações presentes nos documentos.
- Não invente informações, valores ou dados que não estejam disponíveis nas fontes.
- Caso não encontre evidências suficientes para responder, declare explicitamente essa limitação.
- Não utilize conhecimento externo para complementar as informações.

Formato:
Apresente uma resposta objetiva e direta, incluindo as fontes utilizadas para fundamentá-la.

Pergunta:
{pergunta do caso de teste}
```

Fator de Mudança e Justificativa

A única mudança principal entre as versões A e B será a formulação do prompt.

Na Versão A, o sistema recebe somente a pergunta do usuário. Na Versão B, são adicionadas instruções explícitas sobre objetivo, contexto, restrições e formato esperado da resposta.

A alteração foi escolhida para avaliar se instruções mais estruturadas melhoram a qualidade das respostas, especialmente quanto à precisão factual, à utilização das fontes e à capacidade de reconhecer a ausência de evidências. Nenhuma outra configuração será intencionalmente modificada entre as versões.

Condições de Comparabilidade

As seguintes condições serão mantidas idênticas nas duas versões:

- **Modelo**: Gemini 2.5 Flash.
- **Casos de teste**: CT01, CT02, CT03, CT04, CT05 e CT06.
- **Workspace**: mesmo workspace e mesmos documentos indexados.
- **Parâmetros**: configuração padrão do workspace.
- **Condições de execução**: sessão limpa a cada execução.
- **Quantidade**: uma execução por caso em cada versão.

O CT06 será tratado como uma variação do CT01, não sendo considerado uma observação independente.

SAÍDAS

Introdução

Esta seção apresenta as saídas obtidas nas execuções dos seis casos de teste, contemplando as versões A (baseline) e B (prompt estruturado) do AnythingLLM. Para cada execução, foram registrados a resposta bruta retornada pelo sistema e o resultado do F1 lexical. As imagens estão registradas em Saídas

O cálculo do F1 lexical foi realizado por meio de um script Python, utilizando os arquivos `.txt` contendo a resposta de referência e a saída gerada pela IA. O script aplica normalização Unicode NFC, conversão para letras minúsculas com `casefold` e tokenização por expressões regulares (`\w+`). Em seguida, calcula a interseção dos tokens considerando suas frequências, obtendo precisão, revocação e a média harmônica entre ambas (F1).

Os resultados são apresentados com três casas decimais. A avaliação qualitativa das respostas, incluindo correção, relevância, suporte nas fontes e identificação de falhas críticas, será realizada posteriormente na seção de Avaliações.

Resultados das Execuções

ID	Resposta bruta	F1 lexical	F1 aplicado a τ (0,5)
CT01-A	A empresa concede vale-refeição no valor de R$ 50,00 por dia útil trabalhado.	0.636	Aprovado
CT01-B	A empresa concede vale-refeição no valor de R$ 50,00 por dia útil trabalhado, creditado mensalmente em cartão benefício. Fonte: Politica-Beneficios.pdf	0.452	Reprovado
CT02-A	A missão da Empresa Exemplo S.A. é "Simplificar a gestão de pequenas e médias empresas por meio de soluções digitais acessíveis, seguras e fáceis de usar, contribuindo para o crescimento sustentável dos nossos clientes."	0.852	Aprovado

CT02-B	A missão da Empresa Exemplo S.A. é simplificar a gestão de pequenas e médias empresas por meio de soluções digitais acessíveis, seguras e fáceis de usar, contribuindo para o crescimento sustentável dos clientes. Fonte: Manual-Organizacional.pdf	0.813	Aprovado
CT03-A	A receita líquida da Empresa Exemplo S.A. no exercício de 2025 foi de R$ 48,6 milhões.	0.364	Reprovado
CT03-B	Não foi possível determinar a receita líquida da empresa no exercício de 2025 com base nas informações disponíveis.	0.000	Reprovado
CT04-A	Os colaboradores terão direito ao plano de saúde após o período de experiência de 90 dias.	0.667	Aprovado
CT04-B	Os colaboradores passam a ter direito ao plano de saúde após o período de experiência de 90 dias. Fonte: Politica-Beneficios.pdf	0.533	Aprovado
CT05-A	Não encontrei informações sobre o valor do bônus anual por desempenho pago aos colaboradores em 2025 nos documentos disponíveis.	0.000	Reprovado
CT05-B	Não foi possível encontrar informações sobre o valor do bônus anual por desempenho pago aos colaboradores em 2025 nos documentos disponíveis.	0.000	Reprovado
CT06-A	A empresa concede vale-refeição no valor de R$ 50,00 por dia útil trabalhado. O crédito é feito mensalmente em cartão benefício, até o 5º dia útil de cada mês. Colaboradores com salário de até R$ 6.000,00 não têm desconto em folha; acima desse valor, o desconto é de 10% do valor do benefício. O auxílio-refeição não é pago em dias de férias, licença ou afastamento, e o saldo não utilizado acumula por até 60 dias.	0.335	Reprovado
CT06-B	A empresa disponibiliza R$ 50,00 de vale-refeição por dia útil trabalhado. Este valor é creditado mensalmente em cartão benefício até o 5º dia útil de cada mês. O benefício não é pago nos dias de férias, licença ou afastamento.	0.292	Reprovado

Conclusão das Saídas

Os resultados do F1 lexical demonstraram diferenças na sobreposição entre as respostas geradas e as referências esperadas. Considerando o limiar de aprovação estabelecido ($\tau = 0,5$), a Versão A obteve três resultados aprovados (CT01, CT02 e CT04), enquanto a Versão B obteve dois (CT02 e CT04).

A Versão A apresentou valores de F1 superiores aos da Versão B em CT01, CT02, CT04 e CT06. Em CT03, a Versão A também obteve resultado superior, embora ambas tenham ficado abaixo do limiar. Em CT05, as duas versões obtiveram F1 igual a zero. Esse resultado evidencia uma limitação da métrica na avaliação de respostas de abstenção, pois diferentes formulações podem expressar corretamente a ausência de informação sem apresentar grande sobreposição lexical com a referência.

Destaca-se o CT06, no qual a Versão A obteve F1 de 0,335, enquanto a Versão B alcançou 0,292. Apesar da maior sobreposição lexical da Versão A, ambas ficaram abaixo do limiar. Além disso, a presença de informações adicionais nas respostas pode influenciar o cálculo, sem necessariamente representar maior qualidade ou precisão.

De modo geral, os resultados indicam que, neste conjunto de testes, a Versão A apresentou melhor desempenho lexical que a Versão B. Entretanto, o F1 lexical, isoladamente, não é suficiente para determinar a qualidade das respostas do AnythingLLM. A métrica pode penalizar diferenças de redação e respostas semanticamente equivalentes, além de não avaliar adequadamente a correção factual ou a pertinência das fontes. Portanto, será necessária a avaliação humana para verificar se as respostas atendem aos critérios de correção, relevância e suporte documental, conforme definido no plano GQM.

AVALIAÇÕES

Introdução

Esta seção apresenta a avaliação da aderência das respostas aos documentos fornecidos, contrastando o comportamento padrão da IA (Versão A) com o comportamento sob um system prompt restrito (Versão B).

A avaliação utiliza três métricas principais, pontuadas de 0 a 2: Correção (C), Relevância (R) e Suporte (S), além da identificação de falhas críticas (como alucinações ou fabricação de dados).

Avaliação R1

Caso	C	R	S	Falha crítica	Justificativa
CT01-A	2	2	2	0	A resposta informa corretamente o valor de R$ 50,00 por dia útil.
CT01-B	2	2	2	0	Valor correto, adicionando o detalhe do cartão benefício e a citação explícita da fonte
CT02-A	2	2	2	0	A missão da empresa foi recuperada e transcrita corretamente.
CT02-B	2	2	2	0	Missão apresentada de forma direta, cumprindo a restrição de formato e citando a fonte.
CT03-A	2	2	2	0	Resposta correta. A IA forneceu um valor correto de (R$ 48,6 milhões).
CT03-B	0	0	0	0	Falha Média:(Falso negativo)Houve uma abstenção incorreta; O documento continha o dado da receita.
CT04-A	2	2	2	0	Informou corretamente o período de experiência de 90 dias para o plano de saúde.
CT04-B	2	2	2	0	Resposta objetiva com o prazo correto e citação formal da política de benefícios
CT05-A	2	2	2	0	Abstenção correta, indicando a falta

					de informações sobre o bônus de 2025.
CT05-B	2	2	2	0	Abstenção justificada, cumprindo rigorosamente a declaração de limitação exigida.
CT06-A	2	2	2	0	Informou o valor correto de R$ 50,00/dia útil e detalhou regras de crédito, acúmulo e faixas de desconto em folha.
CT06-B	2	2	2	0	Resposta objetiva com o valor correto de R$ 50,00/dia útil e condições de concessão, aderente aos documentos.

Avaliação R2

Caso	Avaliação R1(C/R//S/FC)	Avaliação R2(C/R/S/FC)	Concordância
CT01-A	2/2/2/0	2/2/2/0	Sim
CT01-B	2/2/2/0	2/2/2/0	Sim
CT05-A	2/2/2/0	2/2/2/0	Sim
CT05-B	2/2/2/0	2/2/2/0	Sim

Resultado da Concordância

Casos avaliados: 4

Casos com concordância: 4

Casos com divergência: 0

Taxa de concordância : 100%

Consenso entre os Avaliadores

A comparação entre as avaliações de R1 e R2 apresentou concordância de 100%. Todos os quatro casos analisados receberam pontuações idênticas nos critérios de Correção, Relevância, Suporte e Falha Crítica.

Dessa forma, não foram identificadas divergências entre os avaliadores, não sendo necessária uma etapa adicional de consenso ou alteração das avaliações originais. As tabelas de R1 e R2 foram preservadas integralmente.

ANÁLISE E DECISÃO

Introdução

Este documento consolida as 12 saídas do experimento (6 casos × versões A e B) e apresenta a análise comparativa e a decisão, conforme o Plano GQM. A Versão A é o baseline (prompt direto) e a Versão B usa o prompt estruturado.

Os valores de F1 são os do Registro das Saídas, com τ = 0,5, e a decisão final vem das avaliações humanas. Conforme o GQM, a decisão considera principalmente a avaliação humana, utilizando o F1 como indicador automático complementar.

Tabela Consolidada

ID	F1	Sinal	C/R/S/FC	Decisão final
CT01-A	0,636	Aprova	2/2/2/0	Aprovada
CT01-B	0,452	Reprova	2/2/2/0	Aprovada
CT02-A	0,852	Aprova	2/2/2/0	Aprovada
CT02-B	0,813	Aprova	2/2/2/0	Aprovada
CT03-A	0,364	Reprova	2/2/2/0	Aprovada
CT03-B	0,000	Reprova	0/0/0/0	Reprovada
CT04-A	0,667	Aprova	2/2/2/0	Aprovada
CT04-B	0,533	Aprova	2/2/2/0	Aprovada
CT05-A	0,000	Reprova	2/2/2/0	Aprovada
CT05-B	0,000	Reprova	2/2/2/0	Aprovada
CT06-A	0,335	Reprova	2/2/2/0	Aprovada
CT06-B	0,292	Reprova	2/2/2/0	Aprovada

Concordância e Métricas por Versão

A comparação considera seis casos por versão. A aprovação humana ocorre quando Correção, Relevância e Suporte recebem nota 2, sem falha crítica. A aprovação automática ocorre quando F1 é igual ou superior a 0,5.

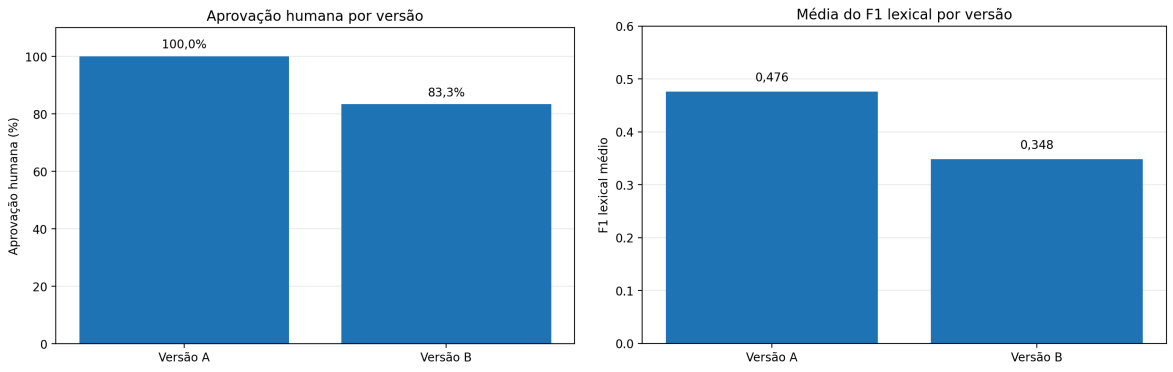
Indicador	Versão A	Versão B
Média do F1	0,476	0,348
Mediana do F1	0,500	0,373
Aprovação automática	3/6 (50,0%)	2/6 (33,3%)
Aprovação humana	6/6 (100%)	5/6 (83,3%)
Falhas críticas	0	0

A Versão A apresentou média e mediana de F1 superiores às da Versão B. Na avaliação humana, a Versão A foi aprovada nos seis casos, enquanto a Versão B foi aprovada em cinco, com reprovação no CT03-B.

A concordância entre o sinal automático e a decisão humana foi de 1 em 12 casos (8,3%). O único caso de concordância foi CT03-B, reprovado tanto automaticamente quanto na avaliação humana. Nos outros 11 casos, o F1 indicou reprovação, embora a avaliação humana tenha aprovado as respostas.

A concordância entre R1 e R2 foi de 4 em 4 casos (100%). Os dois avaliadores atribuíram as mesmas pontuações aos quatro casos selecionados: CT01-A, CT01-B, CT05-A e CT05-B.

Gráfico



Análise de Divergências e Casos-Limite

O principal caso de divergência entre as avaliações automática e humana ocorreu nas respostas aprovadas pelos avaliadores, mas reprovadas pelo F1. Isso aconteceu porque a métrica considera a sobreposição lexical entre a resposta e a referência, não sendo capaz de reconhecer plenamente equivalência de significado ou correção factual.

O CT05 ilustra essa limitação. As duas versões realizaram a abstenção esperada, pois os documentos disponíveis não apresentavam o valor do bônus anual por desempenho pago em 2025. Apesar disso, ambas receberam F1 igual a zero. A avaliação humana considerou as duas respostas corretas, relevantes e sustentadas pela ausência de evidência nos documentos.

Outro caso importante é o CT06. As respostas das duas versões foram consideradas corretas pelos avaliadores, mas ficaram abaixo do limiar de F1. A presença de informações adicionais sobre o benefício aumentou a diferença entre as respostas e a referência curta, sem representar necessariamente um erro factual.

O CT03-B representa o principal problema funcional identificado na Versão B. Embora o relatório financeiro contenha a receita líquida de R$ 48,6 milhões, a resposta afirmou que não foi possível determinar o valor. Trata-se de um falso negativo: o sistema deixou de recuperar uma informação disponível na base documental. Por isso, o caso recebeu notas zero em Correção, Relevância e Suporte na avaliação humana.

Também é importante observar que CT06 é uma paráfrase do CT01, e não uma observação totalmente independente. Os dois casos verificam essencialmente a recuperação do mesmo valor de vale-refeição, com formulações diferentes. Assim, o conjunto possui seis casos registrados, mas não seis objetivos de informação completamente distintos.

Não foram registradas falhas críticas nas avaliações humanas. Entretanto, a falha média identificada em CT03-B continua relevante, pois demonstra que o prompt estruturado não impediu uma abstenção incorreta diante de evidência disponível.

Decisão

- **Manter a Versão A como baseline**

Com base nos resultados desta rodada, a decisão é manter a Versão A como baseline e não promover a Versão B para uso como configuração preferencial neste momento.

A decisão é sustentada pelos seguintes resultados:

- A Versão A obteve aprovação humana em 6 dos 6 casos (100%), enquanto a Versão B obteve aprovação em 5 dos 6 casos (83,3%).
- A Versão A apresentou média de F1 de 0,476, superior à média de 0,348 da Versão B.
- A Versão B apresentou uma falha de recuperação no CT03, abstendo-se incorretamente de informar a receita líquida de 2025, apesar de o dado estar disponível no documento.
- Não foram identificadas falhas críticas, mas a falha funcional no CT03-B impede considerar a Versão B superior ou pronta para substituir o baseline.

A Versão B poderá ser revisada em uma próxima rodada, com atenção especial à recuperação de informações que estão presentes nos documentos. Após o ajuste, será necessário executar novamente os casos de teste e realizar nova avaliação, mantendo as condições de comparação controladas.

O critério para uma futura promoção da Versão B deverá incluir aprovação humana nos seis casos, ausência de falhas críticas e ausência de falhas funcionais como a observada no CT03-B. O F1 deverá ser considerado em conjunto com a avaliação humana, e não como critério isolado de qualidade.

Um diagrama de decisão pode ser encontrado aqui.

Respostas às Questões de Análise

Q1. A versão B atende melhor à tarefa do que a versão A?

Não. A aprovação humana foi de 6/6 na Versão A e 5/6 na Versão B. A diferença corresponde à falha do CT03-B, em que a Versão B não recuperou uma informação existente no relatório financeiro. Além disso, a Versão A apresentou média de F1 superior. Portanto, nesta rodada, a Versão B não demonstrou ganho de qualidade.

Q2. O sinal automático representa a adequação das respostas?

Não de forma suficiente. A concordância entre o sinal automático e a avaliação humana foi de apenas 1/12 (8,3%). O F1 reprovou respostas que os avaliadores consideraram corretas, como as abstenções do CT05 e as respostas dos demais casos com redação diferente da referência. Isso demonstra que a métrica lexical deve ser utilizada como indicador complementar, não como substituta da avaliação humana.

Limitações

- O experimento contém apenas seis casos de teste, sendo CT06 uma paráfrase de CT01. Portanto, a variedade de perguntas e de informações avaliadas é limitada.
- O conjunto de documentos é pequeno e restrito a materiais organizacionais específicos. Os resultados não garantem o mesmo comportamento em outras bases documentais.
- O F1 lexical mede sobreposição de palavras e não avalia diretamente equivalência semântica, correção factual, relevância ou qualidade da recuperação de fontes.
- A avaliação humana utiliza uma escala de 0 a 2 e foi realizada por dois avaliadores, mas R2 analisou somente quatro das doze saídas. A concordância de 100% se aplica apenas a esses quatro casos.
- O resultado do experimento representa as execuções realizadas nas condições registradas. Alterações no modelo, na versão do sistema, nos parâmetros ou nos documentos podem modificar as respostas.
- A decisão é válida para esta rodada e para os casos avaliados. Uma conclusão mais ampla exigiria maior quantidade e diversidade de perguntas, novas execuções e avaliação humana adicional.

REFERÊNCIAS

ANTHROPIC. Claude: AI & Anthropic API Documentation. San Francisco: Anthropic, 2026. Disponível em: https://www.anthropic.com/claude. Acesso em: 21 out. 2026.

GOOGLE. Gemini: Models & API Documentation. Mountain View: Google, 2026. Disponível em: https://ai.google.dev/. Acesso em: 21 out. 2026.

MINTPLEX LABS. AnythingLLM: The all-in-one AI application for desktop & enterprise. Versão 1.0. San Francisco: GitHub, 2026. Disponível em: https://github.com/mintplex-labs/anything-llm. Acesso em: 21 out. 2026.